

گزارش جامع و متن ارائه

Energy Optimization In IoT Using ML

نام دانشجو: احمد آرامش

استاد: دکتر باقری زاده

درس: شبکه های بی سیم

نقشه کلی گزارش

این گزارش ابتدا مسئله انرژی و مقیاس پذیری در LoRaWAN و چرایی محدودیت های ADR استاندارد را صورت بندی می کند. سپس سه رویکرد یادگیری محور را بررسی می کند:

- مقاله 1 (LP-MAB): یادگیری متمرکز روی Network Server برای انتخاب چندپارامتری (SF/TP/CF/CR) با چارچوب Multi-Armed Bandit و ترکیب SE+EXP3.

- مقاله 2 (ML-Assisted TPC): پیش بینی SNR و کنترل توان/پارامترها به صورت غیرمتمرکز روی End Node با داده میدانی و مدل های یادگیری ماشین، با هدف کاهش وابستگی به تاریخچه SNR و کاهش downlink.

- مقاله 3 (Intelligent Resource Allocation): رویکرد ترکیبی (تخصیص توان متمرکز با یادگیری نظارت شده + تخصیص SF/CR غیرمتمرکز با contextual bandit/RL) با تمرکز بر معیارهای سطح شبکه نظیر Goodput و EPP.

1) مقدمه: دنیای دستگاه های متصل و چالش بزرگ باتری در IoT/LPWAN

تصور کنید هزاران حسگر کوچک در یک مزرعه هوشمند یا در سراسر یک شهر بزرگ پراکنده شده اند. این حسگرها، که بخشی از اینترنت اشیاء (IoT) هستند، مانند پیام رسان های کوچکی عمل می کنند که داده های حیاتی (مانند رطوبت خاک، کیفیت هوا یا وضعیت تجهیزات) را از فواصل دور جمع آوری و ارسال می کنند. **برای اینکه این**

پیام‌رسان‌ها بتوانند داده‌های کوتاه را در بردهای بلند منتقل کنند، به خانواده‌ای از شبکه‌ها با طراحی خاص نیاز داریم.

از منظر ارتباطی، این نیاز با شبکه‌های (Low-Power Wide-Area Networks (LPWAN هدف‌گذاری می‌شود؛ فناوری‌هایی که برای **برد زیاد، نرخ داده پایین و مصرف انرژی کم** طراحی شده‌اند. در مقاله LP-MAB نیز به همین منطق اشاره می‌شود: با رشد سریع تعداد دستگاه‌های IoT (در متن مقاله رقم 22 میلیارد تا سال 2025 ذکر شده است) و نیاز به ارتباطات کم‌مصرف و دوربرد، LPWAN‌ها به گزینه‌های جدی تبدیل شده‌اند و حتی برای **برخی کاربردها عمر باتری تا حدود 10 سال** می‌رسانند.

در این میان، **LoRaWAN** (شبکه گسترده دوربرد مبتنی بر LoRa) یکی از **نمونه‌های مهم LPWAN است**. برخلاف فناوری‌های کوتاه‌برد مثل Wi-Fi/بلوتوث که برد محدود دارند یا شبکه‌های سلولار که معمولاً هزینه/مصرف انرژی بالاتری تحمیل می‌کنند، LoRaWAN برای سناریوهای پیام‌های کوتاه، نرخ داده پایین و انرژی کم مناسب‌سازی شده است. همین موضوع باعث می‌شود در کاربردهایی که دسترسی فیزیکی به حسگر برای تعویض باتری سخت و پرهزینه است (مثلاً سنسورهای جنگل، سد، رودخانه، یا پایش‌های محیطی)، جذابیت عملیاتی بالایی داشته باشد. مقاله ML-Assisted TPC نیز دقیقاً روی چنین کاربردهایی و ضرورت «پایداری و انرژی‌کارایی» تاکید می‌کند و نمونه‌هایی مانند پایش آتش‌سوزی جنگل، سطح سد، کیفیت رودخانه و... را در انگیزش مسئله ذکر می‌کند. اما «کم‌مصرف بودن» به‌تنهایی مسئله را حل نمی‌کند: در بسیاری از کاربردهای IoT انبوه، دستگاه‌های پایانی (**End Devices/End Nodes**) **باتری‌محورند** و باید **سال‌ها بدون سرویس‌دهی مجدد کار کنند**. بنابراین مصرف انرژی عملاً به یکی از مهم‌ترین معیارها تبدیل می‌شود؛ در عین حال شبکه باید تحویل موفق بسته‌ها را نیز حفظ کند (قابلیت اطمینان). در LoRaWAN، علاوه بر **افت کیفیت کانال و پدیده‌های تضعیف/نویز، افزایش تعداد گره‌ها احتمال برخورد (Collision) و ارسال مجدد** را تشدید می‌کند و انرژی را مستقیماً هدر می‌دهد.

مسئله محوری: چگونه می‌توان پارامترهای انتقال را طوری تنظیم کرد که هم‌زمان نرخ تحویل بسته (PDR/PRR) بالا بماند و مصرف انرژی حداقل شود؛ بدون آنکه سربار محاسباتی یا تغییرات پروتکلی سنگینی به دستگاه‌های محدود تحمیل شود؟

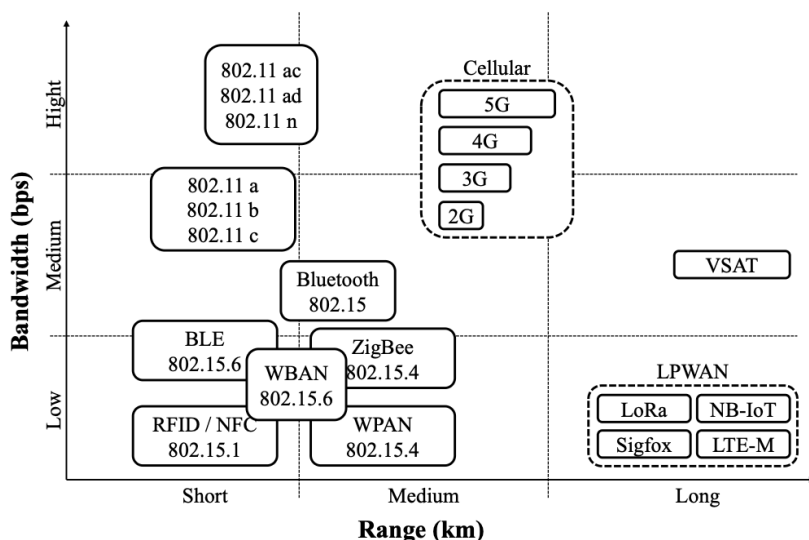


Figure 1. Range of wireless protocols, according to [10] and our own knowledge and experience.

این تصویر نشان می‌دهد: چرا LoRaWAN از منظر برد و مصرف انرژی برای پیام‌های کوتاه مناسب است و چرا Wi-Fi/سلولار... در این نقطه بهینه نیستند.

2) پیش‌زمینه فنی: معماری LoRaWAN و محل تصمیم‌گیری سازوکارهای تطبیقی

2-1) معماری شبکه (Star-of-Stars)

LoRaWAN معمولاً با توپولوژی star-of-stars مدل می‌شود: دستگاه‌های پایانی (ED/EN) پیام‌های uplink را پخش می‌کنند، یک یا چند Gateway (GW) آن‌ها را دریافت کرده و به NS (Network Server) تحویل می‌دهد؛ سپس NS پیام را به سرور/کاربرد اپلیکیشن مسیریابی می‌کند. مقاله LP-MAB این معماری را صریحاً توضیح می‌دهد و نشان می‌دهد که uplink‌ها به صورت broadcast بوده و ED به GW خاصی «اختصاص»

داده نمی‌شود؛ چند GW ممکن است یک پیام را دریافت کنند و سپس به NS ارسال شود.

این معماری اهمیت دارد، چون نقطه تصمیم‌گیری بسیاری از مکانیزم‌های تطبیقی (از جمله ADR استاندارد، LP-MAB و همچنین برخی رویکردهای غیرمتمرکز مانند TPC‌های اجراشونده روی EN) دقیقاً در تعامل $NS \leftrightarrow ED$ معنا پیدا می‌کند.

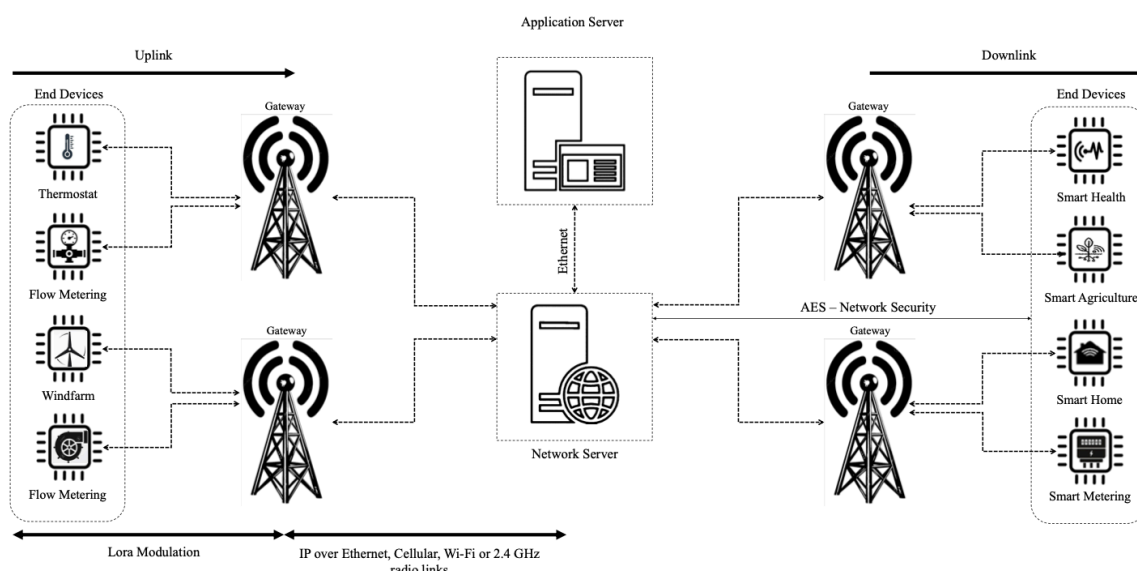


Figure 2. LoRaWAN network architecture.

این شکل نشان می‌دهد: دستگاه‌های پایانی (ED) پیام uplink را به‌صورت broadcast ارسال می‌کنند، چند Gateway می‌توانند همان پیام را دریافت کنند و سپس پیام به NS (Network Server) می‌رسد. نتیجه مهم این است که بسیاری از روش‌های تطبیقی (به‌ویژه روش‌های متکی به فرمان/ACK) عملاً تحت محدودیت ظرفیت downlink و سیاست‌های duty-cycle قرار می‌گیرند، و این محدودیت باید در تحلیل انرژی و مقیاس‌پذیری دیده شود.

3) پارامترهای کلیدی لایه فیزیکی LoRa و اثرات غالب (Trade-off) های (حاکم)

در LoRa، کیفیت لینک ارتباطی و انرژی به شدت تحت تاثیر انتخاب پارامترهای انتقال است. مقاله LP-MAB پارامترهای اصلی قابل پیکربندی را معرفی می‌کند و دامنه‌های رایج را نیز مشخص می‌کند: SF در بازه 7 تا 12، TP در بازه 2 تا 14 dBm، همچنین CF، CR و BW. ترکیب این مقادیر یک فضای حالت بزرگ ایجاد می‌کند؛ هر انتخاب می‌تواند هم بر قابلیت دریافت و هم بر انرژی و اشغال کانال اثر بگذارد.

جدول 1 - اثر غالب افزایش پارامترها و پیامدهای شبکه‌ای/عملیاتی

پارامتر	اثر غالب افزایش پارامتر	پیامدهای شبکه‌ای/عملیاتی (Trade-off)
فاکتور پخش (SF (Spreading Factor	حساسیت گیرنده و برد افزایش می‌یابد.	ToA افزایش می‌یابد (اغلب به صورت شدید/نمایی) \Rightarrow نرخ داده کاهش می‌یابد \Rightarrow اشغال کانال بیشتر می‌شود و احتمال برخورد (Collision) افزایش می‌یابد.
توان ارسال (TP (Transmission Power	احتمال موفقیت دریافت و پایداری لینک افزایش می‌یابد.	انرژی مصرفی افزایش می‌یابد \Rightarrow در شبکه‌های متراکم می‌تواند تداخل (Interference) را تشدید کند و روی سایر گره‌ها اثر منفی بگذارد.
نسبت بیت های داده به بیت های کل مثل (۴/۵ و ۴/۸) (CR (Coding Rate	مقاومت در برابر خطا/نویز بهتر می‌شود.	سربار افزوده می‌شود \Rightarrow طول پیام فیزیکی و ToA افزایش می‌یابد \Rightarrow احتمال برخورد و انرژی مصرفی بالا می‌رود.
عرض کانال BW (Bandwidth)	BW بیشتر می‌تواند ToA را کاهش دهد و نرخ داده را بالا ببرد (برای SF ثابت)	حساسیت گیرنده کاهش می‌یابد \Rightarrow برد/Robustness معمولاً بدتر می‌شود؛ در محیط نویزی/تداخل‌دار احتمال افت لینک بیشتر است؛ ممکن است برای حفظ لینک مجبور شوید SF/TP را افزایش دهید (جبران اثر \uparrow BW)؛

محدودیت‌های مقرراتی/پلن فرکانسی و پشتیبانی گیت‌وی/شبکه می‌تواند استفاده از BWهای بزرگ‌تر را محدود کند.		
به پلن فرکانسی منطقه و پشتیبانی شبکه/گیت‌وی وابسته است و همیشه در اختیار گره نیست؛ پیچیدگی پیکربندی و مدیریت شبکه بیشتر می‌شود؛ اگر درست مدیریت نشود می‌تواند منجر به عدم تعادل بار کانال‌ها یا تداخل بین کانالی در برخی سناریوها شود.	توزیع ترافیک روی کانال‌های بیشتر \Rightarrow کاهش Collision و افزایش ظرفیت/پایداری شبکه در شبکه‌های متراکم	تنوع (CF / Channel diversity) کانال/تعداد کانال‌های قابل استفاده
سازوکارهای تطبیقی برای توزیع بار روی SFها/کانال‌ها و کاهش ToA اهمیت بیشتری پیدا می‌کنند.	با افزایش تعداد گره‌ها، بار کانال و نرخ برخورد افزایش می‌یابد.	تراکم گره‌ها

3-1) معیارهای ارزیابی (PDR/EC) و مشتقات

- **PDR/PRR**: نسبت بسته‌های دریافت‌شده توسط سرور شبکه به کل بسته‌های ارسال‌شده.
- **EC (Energy Consumption)**: انرژی مصرف‌شده؛ در LP-MAB علاوه بر PDR، نمودارهایی با انرژی (و گاهی انرژی نرمال‌شده نسبت به تحویل مانند Energy Consumption per PDR) گزارش می‌شود.
- **EPP (Energy Per Packet)**: انرژی به ازای هر بسته موفق؛ در مقاله Intelligent Resource Allocation برای تحلیل شبکه‌های پرتراکم معیار کلیدی است.
- **Goodput**: نرخ داده مفید در سطح اپلیکیشن که تابعی از PDR و بار ترافیک است (در مقاله Intelligent Resource Allocation گزارش می‌شود).

برای حفظ شهود، می‌توان این موازنه را شبیه «صحبت کردن در یک اتاق شلوغ» دید: اگر بخواهید پیامتان حتماً شنیده شود (PDR بالا)، باید بلند (TP بالا) و شمرده (SF بالا) صحبت کنید؛ این کار انرژی/زمان بیشتری مصرف می‌کند. برعکس، صحبت آرام‌تر و سریع‌تر انرژی کمتری مصرف می‌کند اما احتمال از دست رفتن پیام بالا می‌رود.

4) استاندارد و چرایی نیاز به رویکردهای هوشمندتر

4-1) چرایی و چگونه عمل می‌کند؟

ADR (Adaptive Data Rate) مکانیزمی برای تنظیم پارامترهای انتقال با هدف بهبود هم‌زمان قابلیت تحویل بسته و انرژی است. ADR معمولاً در NS اجرا می‌شود و از طریق MAC Command ها به ED/EN دستور تغییر پارامترها را می‌دهد.

در ادبیات مقاله‌ها، کیفیت لینک در ADR با شاخص‌هایی از خانواده SNR/SINR روی پنجره‌ای از بسته‌های اخیر سنجیده می‌شود (معمولاً 20 بسته). سپس با افزودن حاشیه لینک (Link Margin) تنظیمات SF/TP انجام می‌گیرد. این طراحی ساده و استاندارد است، اما در محیط‌های پویا و پرتراکم چالش‌زا می‌شود.

4-2) مکانیزم‌های مرجع مورد مقایسه (Baseline)

- No-ADR: پیکربندی ثابت و بدون سازوکار تطبیقی (خط مبنا).
- ADR-MAX: تصمیم‌گیری مبتنی بر بیشینه کیفیت لینک در پنجره 20 بسته اخیر (در LP-MAB با max SINR معرفی شده است).
- ADR-AVG: تصمیم‌گیری مبتنی بر میانگین کیفیت لینک در پنجره 20 بسته اخیر برای کاهش خوش‌بینی.
- ADR-Lite: طرح کم‌پیچیدگی که تصمیم را با اتکا به بسته آخر اتخاذ می‌کند (سریع اما بالقوه کم‌دقت‌تر).

(4-3) محدودیت‌های ADR سنتی

- همگرایی/انطباق کند در شرایط ارسال‌های کم‌تعداد: پنجره 20 نمونه دیر تکمیل می‌شود و داده‌های گذشته ممکن است نماینده وضعیت فعلی کانال نباشند.
- خوش‌بینی ناشی از اتکا به بیشینه پنجره ($SNR_{max}/SINR_{max}$): در برابر بهبودهای گذرا آسیب‌پذیر است و تغییرات پایدار را خوب بازتاب نمی‌دهد.
- حاشیه اطمینان بزرگ و اتلاف انرژی (Overestimation از مسیر LM): افزایش LM منجر به افزایش TP/SF و در نتیجه افزایش ToA و EC می‌شود.

(5) روش اول (مقاله 1): LP-MAB - پیکربندی تطبیقی متمرکز با Multi-Armed Bandit روی NS

(5-1) ایده و مدل

الگوریتم LP-MAB (Low-Power Multi-Armed Bandit) یک راهکار متمرکز است که روی **Network Server** اجرا می‌شود و مسئله تخصیص پارامترهای انتقال را به یک مسئله MAB (Multi-Armed Bandit) نگاشت می‌کند. مقاله به صورت صریح می‌گوید LP-MAB یک ADR مبتنی بر RL است که با ترکیب دو روش **EXP3** و **Successive Elimination (SE)** طراحی شده تا هم ویژگی‌های محیط خصمانه/غیرایستا LoRa را پوشش دهد و هم زمان اکتشاف را کوتاه کند.

قیاس «ماشین اسلات» برای شهود:

- قمارباز: سرور شبکه (NS)
- ماشین‌های اسلات: ترکیبات مختلف پارامترهای انتقال (SF, TP) و در توسعه‌ها CF و CR)

- جایزه/پاداش: موفقیت تحویل (با تکیه بر سیگنال ACK/بازخورد) با ترجیح انرژی کمتر

5-2) انگیزه متمرکز بودن

مزیت کلیدی این است که یادگیری و محاسبات سنگین روی NS انجام می‌شود، بنابراین EDها بار محاسباتی اضافی تحمل نمی‌کنند و انرژی ارزشمند خود را حفظ می‌کنند.

5-3) نوآوری الگوریتمی: ترکیب SE و EXP3

EXP3 برای محیط‌های خصمانه مناسب است اما اکتشاف طولانی دارد؛ SE اکتشاف را کوتاه می‌کند اما برای خصمانه بودن به تنهایی کافی نیست. LP-MAB با طراحی دو مرحله‌ای از مزیت‌های هر دو استفاده می‌کند: ابتدا با SE فضای عمل را سریع‌تر پالایش می‌کند و سپس با EXP3 بهره‌برداری مقاوم‌تری ارائه می‌دهد.

Algorithm 1: Initialization of LP-MAB.

```

1 Set  $t = 0$ .
2 Initialization:
3   Set  $u \in \mathcal{U}$  to be the  $u$ th ED.
4   Set  $|\mathcal{U}|$  to be the total number of EDs, so that  $\mathcal{U} = \{ED_1, ED_2, \dots, ED_U\}$ .
5   Set  $|\mathcal{A}|$  to be the total number of actions, so that
       $\mathcal{A} = \{a_0^u, a_1^u, \dots, a_{|\mathcal{A}|-2}^u, a_{|\mathcal{A}|-1}^u\}$ .
6   Set  $k$  to be the index of an action  $a_k^u$ , such that  $a_k^u = \{SF_k, TP_k, CF_k, CR_k\}$  is the
       $k$ th chosen action for the  $u$ th ED.
7   Check and set  $T$  and  $T_{rem}$  to be the total time and the remaining time of the
      simulation, respectively.
8   if  $T_{rem} \leq 0$  then
9     | end the simulation.
10  end
11  Set #GW to be the number of GWs.
12  Set  $L^{\text{EXP}} = \lceil \frac{|\mathcal{U}|}{\text{\#GW} \times 100} \rceil$ , so that  $T_{L^{\text{EXP}}}$  is the time required for the exploration
      phase.
13  Set  $L^{\text{EE}} = \lceil \frac{T_{L^{\text{EXP}}}}{T_{rem}} \rceil \times |\mathcal{A}|$ , so that  $T_{L^{\text{EE}}}$  is the time required for the exploitation
      phase.  $L^{\text{EE}}$  should initially be considerably larger than  $L^{\text{EXP}}$ .
14  Set  $N_{a_k^u} = 0, P_{a_k^u}(t = 0) = \text{nan}, W_{a_k^u}(t = 0) = 1, \forall a_k^u \in \mathcal{A}$ .
      ( $\text{nan}$  standing for "not a number".)
15  Set learning rate  $\gamma = \min \left\{ 1, \sqrt{\frac{|\mathcal{A}| \log(|\mathcal{A}|)}{(e-1)T}} \right\}, e = 2.71$ .
16   $R_{a_k^u}(t) = \begin{cases} 1.0, & \text{if ACK is received, } TP_k = 02, \\ 0.8, & \text{if ACK is received, } TP_k = 05, \\ 0.6, & \text{if ACK is received, } TP_k = 08, \\ 0.4, & \text{if ACK is received, } TP_k = 11, \\ 0.2, & \text{if ACK is received, } TP_k = 14, \\ 0.0, & \text{if ACK is not received.} \end{cases}$ 

```

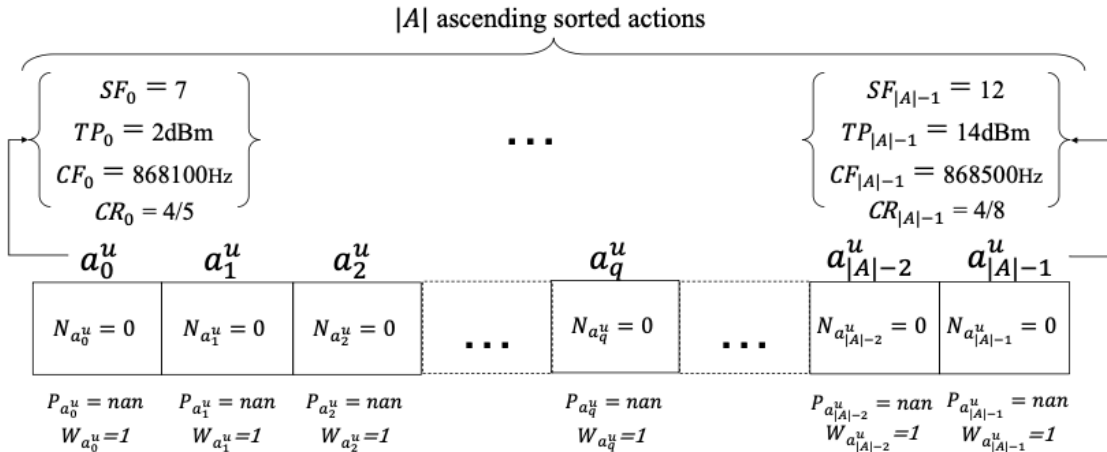


Figure 4. The initialization of LP-MAB for the u th ED.

Algorithm 2: Exploration Phase of LP-MAB.

Output: $P_{a_k^u}(t+1), W_{a_k^u}(t+1)$

- 1 Run the **Initialization** process of Algorithm 1.
- 2 Set $k = 0$.
- 3 **while** $\forall a_k^u \in \mathcal{A}, N_{a_k^u} \leq L^{\text{EXP}}$ **do**
- 4 **if** $k = |\mathcal{A}|$ **then**
- 5 set $k = 0$.
- 6 **end**
- 7 Select and transmit, performing action a_k^u , then set $N_{a_k^u} = N_{a_k^u} + 1$.
- 8 Wait for the reception or non-reception of the ED's ACK.
- 9 Update reward $R_{a_k^u}(t)$ using line 16 of Algorithm 1.
- 10 Set $P_{a_k^u}(t+1) = (1 - \gamma) \left(\frac{W_{a_k^u}(t)}{\sum_{a_k^u \in \mathcal{A}} W_{a_k^u}(t)} \right) + \frac{\gamma}{|\mathcal{A}|}$.
- 11 Set $P_{a_k^u}(t+1) = \frac{P_{a_k^u}(t+1)}{\sum_{a_k^u \in \mathcal{K}} P_{a_k^u}(t)}$.
- 12 Set $W_{a_k^u}(t+1) = W_{a_k^u}(t) \times \exp \left(\frac{\gamma R_{a_k^u}(t)}{|\mathcal{A}| \times P_{a_k^u}(t+1)} \right)$.
- 13 Set $k = k + 1$.
- 14 **end**

این شکل نشان می‌دهد: چرخه تصمیم‌گیری الگوریتم چگونه بین پالایش فضای عمل (حذف گزینه‌های ضعیف‌تر در اکتشاف) و سپس انتخاب‌های احتمالاتی مقاوم در برابر تداخل (بهره‌برداری) جابه‌جا می‌شود. همچنین مشخص می‌کند چه زمانی یک انتخاب “کم‌ارزش” می‌شود و احتمال انتخابش کاهش می‌یابد.

5-4) فرآیند دو مرحله‌ای: اکتشاف و بهره‌برداری

- مرحله اکتشاف: آزمودن سیستماتیک تنظیمات مختلف و حذف گزینه‌های نامناسب با هزینه اکتشاف کوتاه‌تر (به کمک SE).
- مرحله بهره‌برداری: استفاده بیشتر از تنظیمات با احتمال موفقیت بالاتر و هزینه انرژی کمتر؛ کاهش/حذف موقت گزینه‌هایی که افت معنی‌دار نشان می‌دهند.

5-5) سیستم پاداش انرژی‌محور و نقش ACK

LP-MAB نه تنها به موفقیت ارسال (دریافت ACK) پاداش می‌دهد، بلکه **میزان انرژی مصرف‌شده را نیز در پاداش وارد می‌کند** تا موفقیت با توان کمتر ارزشمندتر باشد.

جدول 2 - نمونه پاداش وابسته به TP (برای توضیح ایده انرژی محور)

پاداش	توان انتقال (TP)	رویداد
1.0	dBm 2	بسته با موفقیت دریافت شد
0.8	dBm 5	بسته با موفقیت دریافت شد
0.6	dBm 8	بسته با موفقیت دریافت شد
0.4	dBm 11	بسته با موفقیت دریافت شد
0.2	dBm 14	بسته با موفقیت دریافت شد
0.0	هر توانی	بسته دریافت نشد


این جدول برای نشان دادن این نکته آورده شده که «در LP-MAB فقط موفقیت دریافت مهم نیست، بلکه موفقیت با انرژی کمتر ارزشمندتر است». این دقیقاً همان مکانیزمی است که الگوریتم را به سمت افزایش عمر باتری سوق می‌دهد.

5-6) محیط ارزیابی و سناریوها


در گزارش‌های فنی و متن مقاله، ارزیابی LP-MAB عمدتاً بر شبیه‌سازی رویدادگسسته (مانند ++FLoRa/OMNeT) متکی است. سناریوها شامل محیط‌های شهری و حومه‌ای با تعداد گره‌های متغیر (مثلاً تا 700)، تنظیمات رایج فیزیکی (مانند $BW=125kHz$) و طول پیام کوتاه است. تحلیل نتایج با معیارهایی مانند PDR و مصرف انرژی (و ترکیب‌های نرمال‌سازی‌شده) انجام می‌شود.

5-7) نتایج کلیدی و تفسیر

نتایج گزارش شده نشان می دهد LP-MAB در بسیاری از سناریوها نسبت به ADRهای مرجع (ADR-MAX/ADR-AVG/ADR-Lite) انرژی کمتری مصرف می کند و همزمان PDR قابل قبولی حفظ می کند. همچنین با افزایش تراکم گره ها، افت PDR اجتناب ناپذیر است اما شیب افت در LP-MAB ملایم تر گزارش شده و به عنوان نشانه مقیاس پذیری بهتر مطرح می شود.




(a) Urban environment




(b) Sub-urban environment

Figure 8. PDR & EC versus different numbers of static EDs in Scenario 1.



(a) Urban environment



(b) Sub-urban environment

Figure 15. PDR & EC versus different values for number of total actions in Scenario 8.

این شکل نشان می‌دهد: افزودن CF معمولاً با توزیع ترافیک روی کانال‌ها می‌تواند برخورد را کاهش دهد و عملکرد را بهتر کند. اما افزودن CR های بالاتر با افزایش سربار و طولانی شدن زمان روی هوا (ToA)، احتمال برخورد را بالا می‌برد و ممکن است انرژی و افت تحویل را بدتر کند.

5-8 نقاط قوت و محدودیت‌ها

• قوت‌ها: دید شبکه‌ای (Global View)، تصمیم‌گیری متمرکز بدون سربار محاسباتی روی ED، بهینه‌سازی چندپارامتری، و کاهش هزینه اکتشاف با SE+EXP3.

• محدودیت‌ها: وابستگی به بازخورد (ACK) و تاثیر محدودیت downlink یا نرخ ارسال پایین بر سرعت یادگیری؛ نتایج عمدتاً شبیه‌سازی و نیازمند کالیبراسیون/آزمون میدانی برای تعمیم.

6 روش دوم (مقاله 2): ML-Assisted TPC - پیش‌بینی SNR و کنترل

توان/پارامترها روی EN

6-1 مسئله از دید مقاله

این مقاله نشان می‌دهد ADR رایج، به دلیل اتکا به SNRmax در پنجره گذشته (معمولاً 20 نمونه)، در کانال‌های با نوسان شدید و ارسال‌های با فاصله زمانی زیاد می‌تواند تصمیم‌های ناکارآمد بگیرد؛ در نتیجه برای حفظ PDR، Link Margin بزرگ‌تر انتخاب می‌شود و انرژی هدر می‌رود.

مقاله مفهوم Me (Margin Excess) را برای توضیح منطق کنترل معرفی می‌کند:

- اگر $Me > 0$ باشد یعنی منابع (توان/پارامترها) بیش از نیاز هزینه شده و انرژی تلف می‌شود.

- اگر $Me < 0$ باشد یعنی پارامترها کافی نیستند و لینک ممکن است شکست بخورد.

در ADR رایج، محاسبه Me به شاخص‌هایی نظیر SNRmax، SNRlimit (وابسته به SF) و Link Margin (LM) گره می‌خورد؛ و همین LM اگر محافظه‌کارانه انتخاب شود، انرژی را بالا می‌برد.

6-2 ایده اصلی: پیش‌بینی SNR فعلی به جای تکیه بر گذشته

هسته راهکار این است که SNR فعلی را با کمک ویژگی‌های محیطی و مدل‌های ML پیش‌بینی کند و سپس با منطق TPC، پارامترها را تنظیم کند. مزیت عملیاتی: اجرای الگوریتم روی EN و کاهش نیاز به downlink (فرمان‌های NS) و افزایش سرعت واکنش.

6-3 داده میدانی، تست‌بد و انتخاب ویژگی

نقطه تمایز این پژوهش اتکا به داده میدانی گسترده است: کمپین اندازه‌گیری چندماهه در Medellín (کلمبیا) با EN‌هایی در فاصله 2 تا 8 کیلومتر از GW. سپس با تحلیل‌های آماری نشان می‌دهد فاصله، فشار بارومتريک و PM2.5 اثر معناداری بر SNR دارند و دما/رطوبت اثر کم‌تری داشته‌اند (در داده‌های مطالعه‌شده).




FIGURE 1. System architecture used for the measurement campaigns. We used four ENs, one GW, one NS (The Things Network), and one database server (MySQL).

این شکل نشان می‌دهد: اجزای سامانه (ENها، Gateway، NS/TTN، پایگاه داده) و مسیر ثبت داده‌ها چگونه است؛ و اینکه SNR و متغیرهای محیطی چگونه همزمان جمع‌آوری و ذخیره شده‌اند تا مدل یادگیری ماشین بر اساس واقعیت میدانی آموزش ببیند.

6-4) مدل‌سازی SNR و انتخاب مدل

در مقاله «Machine-Learning-Assisted Transmission Power Control...»، مسئله پیش‌بینی SNR به صورت یک مسئله رگرسیون صورت‌بندی می‌شود تا به جای اتکا به

تاریخچه SNR (مانند ADR)، بتوان «SNR فعلی» را از روی متغیرهای قابل اندازه‌گیری تخمین زد و سپس تصمیم کنترل توان/پارامترها را دقیق‌تر و کم‌مصرف‌تر انجام داد.

فرآیند آماده‌سازی داده و آموزش مدل‌ها در مقاله به‌صورت مهندسی‌شده و قابل اتکا گزارش می‌شود: داده‌های میدانی ابتدا از نظر نقاط پرت پالایش می‌شوند (با استفاده از معیارهایی مانند فاصله ماحالانوبیس)، سپس داده‌ها به‌صورت منظم نمونه‌برداری/بازنمونه‌گیری می‌شوند تا پایگاه داده برای آموزش پایدارتر شود. پس از آن، داده‌ها به مجموعه آموزش و آزمون تقسیم شده و برای کاهش ریسک بیش‌برازش، اعتبارسنجی متقاطع پنج-بخشی (five-fold cross-validation) انجام می‌شود. در کنار این، برای هر مدل، جستجوی شبکه‌ای/شبکه تصادفی (grid/random search) جهت انتخاب هایپرپارامترها **با هدف کمینه کردن RMSE** (و کنترل انحراف معیار RMSE) به کار می‌رود. این چارچوب آموزشی از این جهت مهم است که نشان می‌دهد نتیجه‌گیری مقاله صرفاً یک مقایسه سطحی نیست، بلکه انتخاب مدل مبتنی بر پروتکل ارزیابی استاندارد و قابل دفاع است.

از نظر «خانواده مدل‌ها»، مقاله دو دسته کلی را مقایسه می‌کند:

1. مدل‌های پارامتریک/رگرسیون: Multiple Linear Regression، Lasso، Ridge و GAM.
2. مدل‌های غیرپارامتریک/یادگیری ماشین: ANN، SVR و Random Forest.

برای سنجش عملکرد، مقاله به‌صورت صریح از دو معیار استفاده می‌کند:

- RMSE (ریشه میانگین مربعات خطا) برای سنجش دقت پیش‌بینی عددی SNR؛
- R^2 برای سنجش میزان واریانس توضیح داده‌شده توسط مدل.

نتایج نشان می‌دهد مدل‌های غیرپارامتریک، به‌طور کلی دقت بهتری ارائه می‌دهند و در میان آن‌ها، **Random Forest عملکرد بسیار رقابتی دارد**: در گزارش مقاله، **کمترین RMSE** آزمون برای RF با عمق درخت 6 به دست آمده است ($RMSE \approx 1.9621$ dB) و

مقدار R^2 نیز در سطح بالا گزارش می‌شود (حدود 0.91). SVR نیز بسیار نزدیک به RF گزارش شده (RMSE آزمون حدود 1.97 dB). همچنین برای ANN، نویسندگان اشاره می‌کنند که چند معماری عملکرد مشابه داشتند و در نهایت یک پیکربندی سبک‌تر را برای سازگاری بهتر با محدودیت‌های عملیاتی انتخاب کرده‌اند (هرچند عملکرد آن از RF/SVR ضعیف‌تر گزارش شده است). جمع‌بندی فنی این بخش این است که اختلاف عملکرد مدل‌ها در حد چند دهم dB در RMSE ممکن است در ظاهر کوچک باشد، اما وقتی خروجی مدل به تصمیم‌های کنترلی TP/SF و در نهایت به انرژی و برخوردها منتهی می‌شود، همین بهبود می‌تواند به صرفه‌جویی معنی‌دار در انرژی و بهبود قابلیت تحویل بسته‌ها بیانجامد.




FIGURE 2. LoRaWAN testbed.

TABLE 3. Analysis of measurement data.

Name	Unit	Min	Median	Mean	Max
SNR	dB	-18.5	-1.5	-3.06	12.8
Distance	m	2140	6100	5107	8260
Temperature	°C	13.9	21.1	21.91	35.1
Rel. humidity	%	10	84.5	77.87	99.8
Bar. pressure	hPa	822.8	845.1	840.5	854.8
PM2.5	$\mu\text{g}/\text{m}^3$	0	6	10	93

این شکل نشان می‌دهد:

- معماری واقعی سامانه اندازه‌گیری (End Nodes، Gateway، Network Server/TTN، پایگاه داده و مسیر ثبت داده‌ها) و اینکه SNR هم‌زمان با داده‌های محیطی چگونه جمع‌آوری و ذخیره شده است؛

- چیدمان/تجهیزات تست‌بد و سناریوی فاصله‌ای گره‌ها از Gateway (در مقیاس چند کیلومتر؛ در مقاله صراحتاً بازه‌ای در حد چند کیلومتر برای فاصله گره‌ها گزارش می‌شود)؛
- پیام کلیدی شکل این است که «داده‌ها دارای تغییرات واقعی فاصله و شرایط محیطی» هستند؛ پس مدل باید بتواند اثر هم‌زمان این تغییرات را روی SNR یاد بگیرد. این دقیقاً همان نقطه‌ای است که مقاله برای توجیه نیاز به مدل‌های ML (به‌خصوص مدل‌های غیرپارامتریک/غیرخطی) از آن استفاده می‌کند: زیرا روابط SNR با محیط و فاصله در داده واقعی ساده و خطی نیست و با قواعد ثابت ADR به‌خوبی پوشش داده نمی‌شود.

5-6) منطق TPC و فلوچارت تصمیم‌گیری

الگوریتم بر اساس SNR پیش‌بینی‌شده، Me (Margin Excess) را محاسبه می‌کند. اگر $Me > 0$ باشد، ابتدا کاهش SF (برای کاهش ToA) و سپس کاهش TP برای ذخیره انرژی انجام می‌شود؛ اگر $Me < 0$ باشد، افزایش SF و سپس تنظیم TP برای حفظ قابلیت اطمینان انجام می‌گیرد.

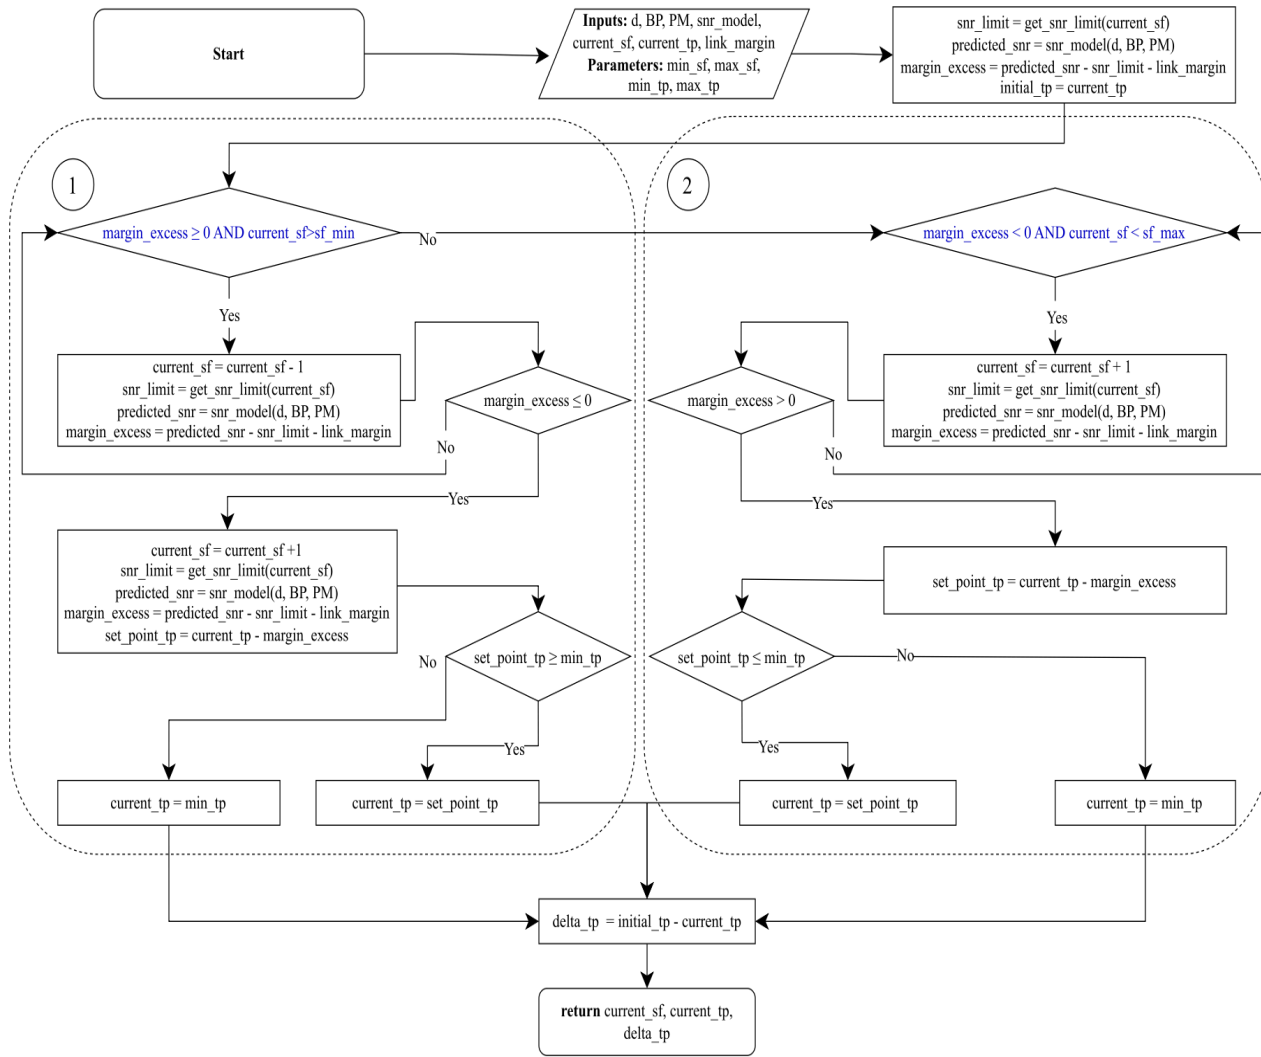


FIGURE 5. Proposed Transmission Power Control using the developed ML-based SNR models.

این شکل نشان می‌دهد: ابتدا SNR پیش‌بینی می‌شود، سپس **Excess Margin** محاسبه می‌گردد و بر اساس علامت آن، تنظیمات **SF** و **TP** به ترتیب مشخص تغییر می‌کند (اولویت کاهش/افزایش **SF** برای کنترل **ToA** و سپس تنظیم **TP**). پیام شکل: تصمیم‌گیری قاعده‌مند است، اما ورودی اصلی آن "پیش‌بینی وضعیت فعلی" است نه "SNRهای گذشته".

6-6) نتایج عددی کلیدی

طبق چکیده/نتیجه‌گیری مقاله، کاهش مصرف انرژی در حدود 47.1 درصد با حفظ **PDR** حدود 99 درصد گزارش شده است. در شبکه‌های متراکم نیز کاهش نرخ برخورد تا حدود

9.5 درصد ذکر شده است. در بخش نتایج، برای برخی مدل‌ها (مانند RF) بهبود انرژی نزدیک به 47.5 درصد گزارش می‌شود.




FIGURE 8. Energy improvement versus PDR for different TPC schemes.

این شکل نشان می‌دهد: جایگاه روش پیشنهادی روی منحنی trade-off نسبت به ADR؛ یعنی برای یک سطح تحویل مشابه، انرژی کمتر مصرف می‌شود (یا برای یک سطح انرژی مشابه، تحویل بهتری حاصل می‌شود). پیام مدیریتی شکل: بهبود ادعاشده صرفاً نظری نیست و روی نمودار عملکرد قابل مشاهده است.




FIGURE 11. Improvement of the analyzed TPC methods compared with the traditional ADR scheme considering different weights for PDR, energy consumption, and collision rate.

مقادیر مثبت به معنی عملکرد بهتر از ADR و مقادیر منفی به معنی افت عملکرد نسبت به ADR است. چهار زیرنمودار، سناریوهای مختلف وزندهی در ارزیابی چندمعیاره را نمایش می‌دهند.

(Energy Consumption) **(we)** Weight of Energy: وزن معیار مصرف انرژی

(Packet Delivery/Reception Ratio) **(wp)** Weight of PDR/PRR: وزن معیار نرخ تحویل/دریافت بسته

(Collision Rate) **(wc)** Weight of Collision: وزن معیار نرخ برخورد

به‌طور معمول مجموع وزن‌ها ۱۰۰٪ است (مثلاً 33.3/33.3/33.3 به معنی اهمیت برابر، و 70/15/15 به معنی اولویت غالب انرژی)

6-7) نقاط قوت و محدودیت‌ها

• قوت‌ها: واکنش سریع به تغییرات محیطی، حذف وابستگی به تاریخچه SNR، کاهش نیاز به downlink برای تنظیم، و اتکا به داده میدانی واقعی.

• محدودیت‌ها: نیاز به آموزش اولیه مدل و کالیبراسیون برای محیط‌های جدید؛ نیاز به سنسورهای محیطی (فشار/PM) که خود هزینه انرژی/هزینه سخت‌افزار دارد.

(7) روش سوم (مقاله 3): Intelligent Resource Allocation in LoRaWAN Using Machine Learning

(7-1) صورت‌بندی مسئله و انگیزه

این مقاله ADR قاعده‌محور را برای سناریوهای «IoT انبوه و پویا» ناکافی می‌داند و مسئله تخصیص منابع را یک مسئله بهینه‌سازی چندهدفه (قابلیت اطمینان، انرژی و ظرفیت) معرفی می‌کند. همزمان در نظر گرفتن همه پارامترهای LoRa-PHY می‌تواند فضای عمل بسیار بزرگ و پیچیدگی بالا ایجاد کند؛ به‌ویژه در حضور تحرک، کانال‌های غیرایستا و ازدحام.

(7-2) روایت شهودی (حفظ متن): پلیس راهنمایی با کتابچه قوانین ساده (ADR)

ADR را می‌توان مثل «پلیس راهنمایی خودکار» شبکه دانست: به هر دستگاه می‌گوید با چه ترکیب SF و TP صحبت کند تا انرژی کمتر مصرف شود و شبکه پایدار بماند. اما در شبکه‌های شلوغ و پویا ضعف‌ها پررنگ می‌شود: ADR کند و محافظه‌کار است و برای ازدحام شدید و تداخل زیاد، قواعد ساده آن پاسخگو نیست. در قیاس شهری، پلیسی را تصور کنید که فقط یک کتابچه قوانین قدیمی دارد و بدون توجه به ترافیک واقعی، دستور ثابت می‌دهد؛ در نتیجه در ساعات شلوغی، هرج‌ومرج رخ می‌دهد. مقاله 3 یک جایگزین هوشمندتر و داده‌محورتر را پیشنهاد می‌کند.

(7-3) مدل دو مرحله‌ای (ML + RL) و ایده Divide and Conquer

نوآوری کلیدی این مقاله تفکیک مسئله به دو زیرمسئله مستقل است:

(الف) تخصیص توان (TP) به صورت متمرکز با یادگیری نظارت شده (Supervised ML)؛
(ب) تخصیص SF/CR به صورت غیرمتمرکز روی گره ها با contextual bandit/RL
(الگوریتم EXP4). این تفکیک فضای عمل مرحله RL را کوچک تر و همگرایی را سریع تر می کند.

7-4) مرحله اول: تخصیص توان با یادگیری نظارت شده (Random Forest)

توان ارسال به عنوان یک مسئله طبقه بندی در نظر گرفته می شود (به دلیل گسسته بودن سطوح توان در سخت افزار LoRa). چند الگوریتم مقایسه می شوند و Random Forest بالاترین دقت گزارش شده را ارائه می دهد. خروجی این مرحله، نگاشت توان حداقل مورد نیاز برای رسیدن به PRR هدف است؛ مزیت عملی این است که مرحله RL مجبور نیست توان را همزمان اکتشاف کند.

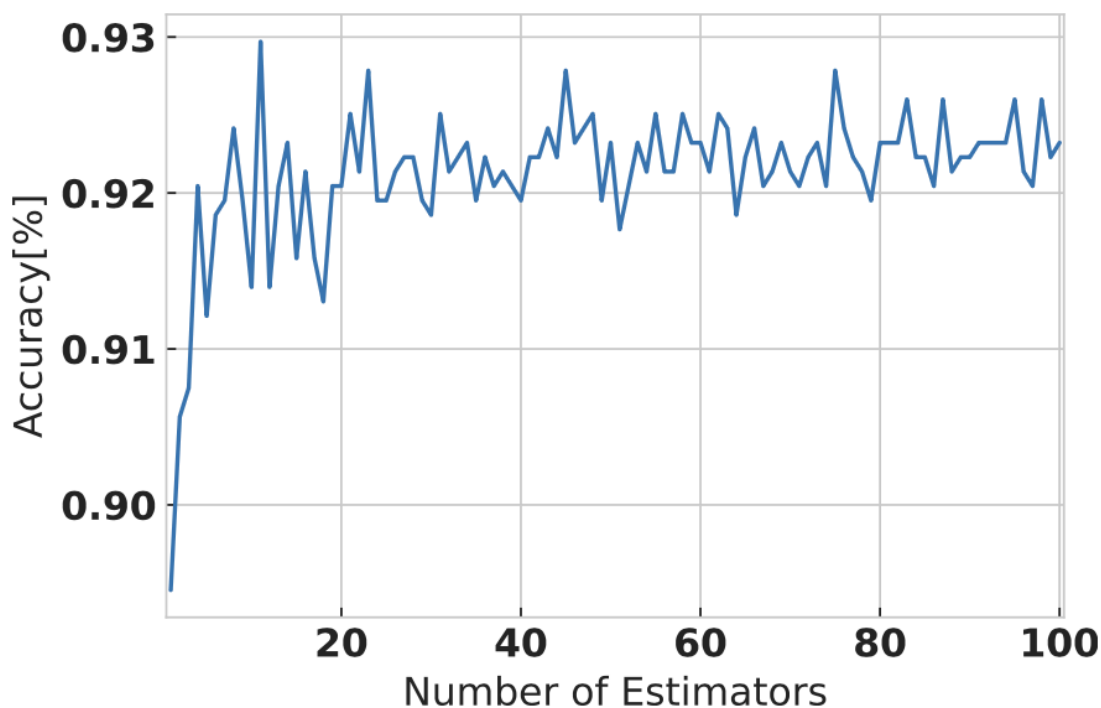


FIGURE 2. Classification accuracy of random forest (RF) algorithm for optimal power allocation.

در نمودار Random Forest، دقت برحسب تعداد estimatorها نمایش داده شده و نقطه بهینه (با هزینه

محاسباتی معقول) قابل مشاهده است؛ یعنی افزایش تعداد estimator بعد از یک نقطه، بهبود اندک/اشباع‌شونده دارد

5-7) مرحله دوم: تخصیص SF/CR با contextual bandit و الگوریتم EXP4

در مرحله دوم، تخصیص SF/CR به صورت contextual multi-armed bandit مدل می‌شود و EXP4 به کار گرفته می‌شود. EXP4 با دریافت مشاوره از «متخصصان» مجازی می‌تواند سریع‌تر از EXP3/EXP3s همگرا شود. یکی از متخصص‌ها مبتنی بر ToA است و SF‌های پایین‌تر را ترجیح می‌دهد تا برخورد کم شود، و متخصص دیگر مبتنی بر تاریخچه موفقیت/ناموفق (EXP3s خانواده) است. این ترکیب همگرایی را حدود 10 برابر نسبت به EXP3s خالص سریع‌تر گزارش می‌کند.

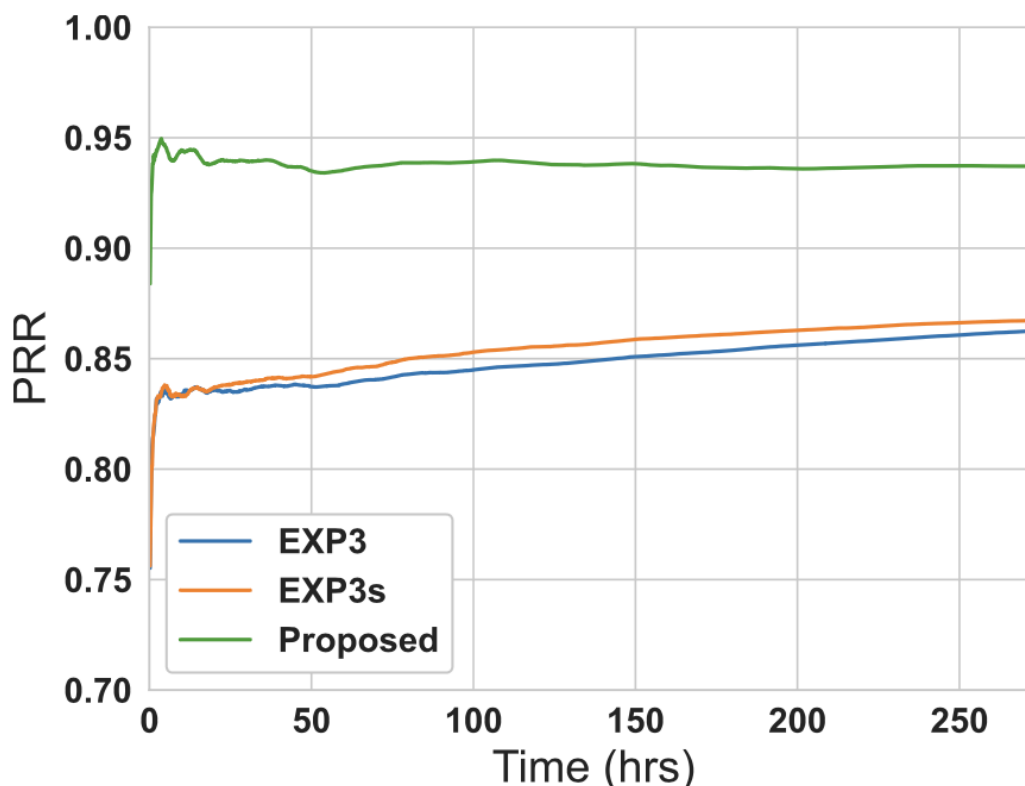


FIGURE 3. Convergence analysis of the proposed and the baseline RL algorithms.

PRR در طول زمان برای EXP4 سریع‌تر بالا می‌آید و زودتر «مسطح» می‌شود (همگرا می‌شود)، در حالی که

روش‌های پایمتر (مثل خانواده EXP3) آهسته‌تر یاد می‌گیرند. پیام شکل: استفاده از «expert advice/context» باعث کاهش هزینه اکتشاف و افزایش سرعت همگرایی شده است.

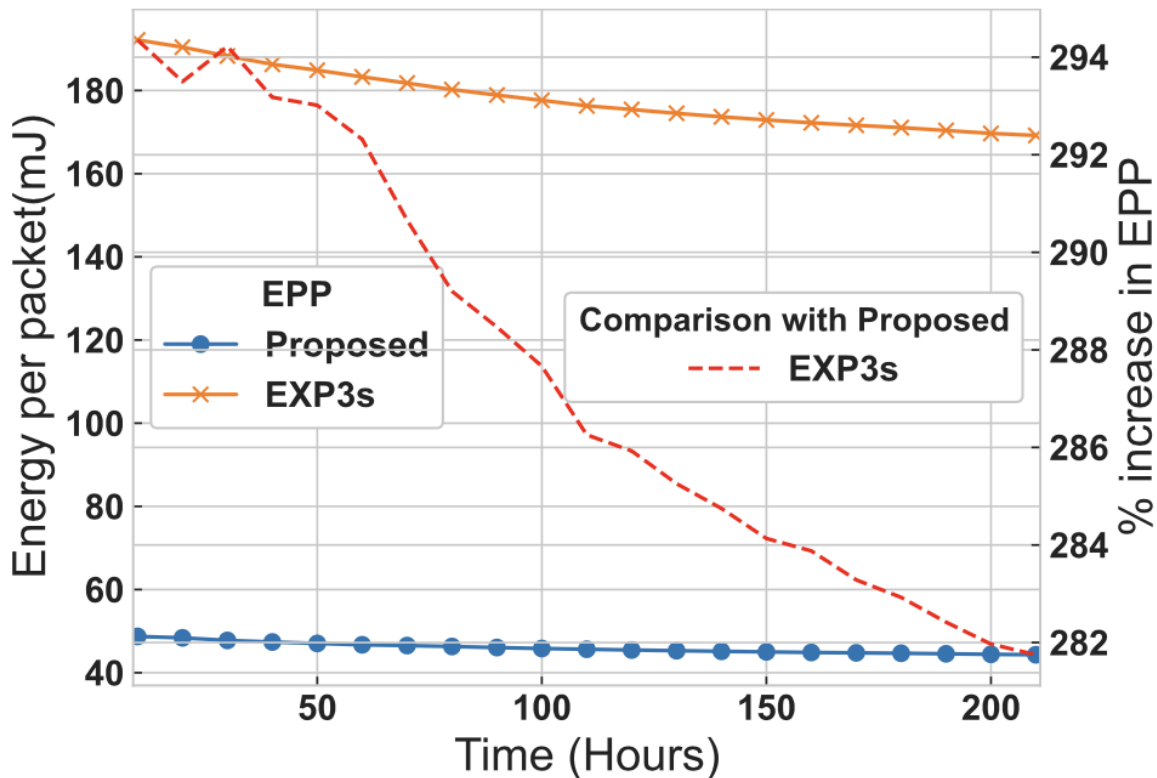


FIGURE 4. EPP for EXP3s and proposed.

این شکل نشان می‌دهد: روش‌های تک‌هدفه که فقط PRR را پیشینه می‌کنند می‌توانند انرژی بیشتری بسوزانند؛ در حالی که رویکرد چندهدفه با مرحله ML برای TP و سپس RL برای SF/CR EPP را بهتر کنترل می‌کند. پیام شکل: در ازدحام بالا، کاهش برخورد/ToA مستقیماً روی EPP اثر می‌گذارد.

7-6) نتایج سطح شبکه: Goodput و EPP

این مقاله علاوه بر PRR، معیارهای سطح شبکه مانند Goodput و EPP را گزارش می‌کند. بر اساس نتایج، چارچوب پیشنهادی در شبکه‌های بزرگ و پرتراکم بهبود قابل توجهی در Goodput و EPP نسبت به روش‌های مرجع ارائه می‌دهد. این نکته نشان می‌دهد که برخورد و ازدحام اگر کنترل نشوند، حتی با PRR مناسب نیز می‌توانند انرژی را به شدت هدر دهند. در یک نقطه عملیاتی گزارش می‌شود که در شعاع مشخص شبکه، «دومین الگوریتم بهتر» دارای EPP حدود 26 برابر بالاتر از روش پیشنهادی است؛ این

یعنی روش پیشنهادی در ازدحام بالا از اتلاف انرژی ناشی از برخورد و اتلاف بسته جلوگیری موثرتری دارد.

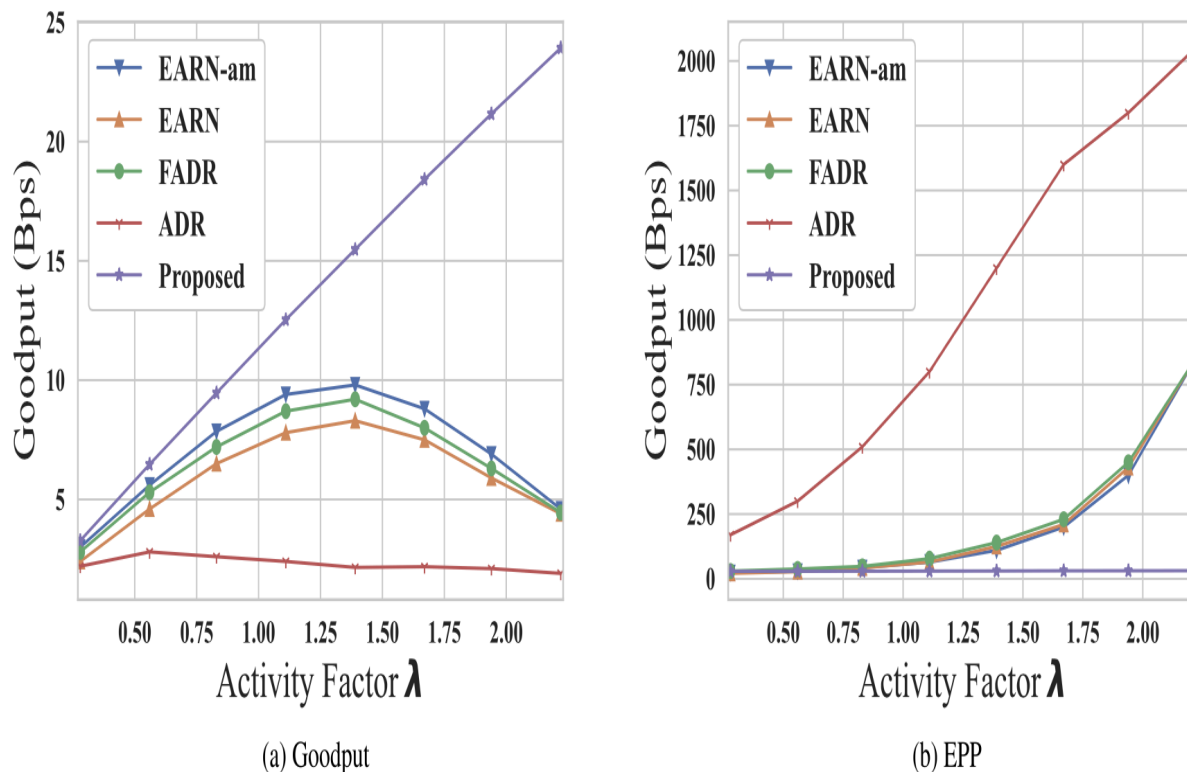


FIGURE 7. Comparing the proposed algorithm with the ADR-based schemes for different traffic loads for cell radius $R = 4.5$ km.

این شکل نشان می‌دهد: با افزایش بار شبکه/تغییر سناریو، برخی سیاست‌ها Goodput را بهتر حفظ می‌کنند و همزمان EPP را پایین‌تر نگه می‌دارند. پیام عملیاتی شکل: روش پیشنهادی فقط یک بهبود نقطه‌ای نیست، بلکه در سناریوهای پرتراکم می‌تواند رفتار شبکه را پایدارتر و کاراتر کند.

7-7) تحرک، آموزش و محدودیت ACK

یکی از ملاحظات عملی این چارچوب، نیاز به ACK در فاز آموزش است که می‌تواند منابع downlink را مصرف کند. مقاله اشاره می‌کند با دوره آموزش محدود (مثلاً حدود یک شبانه‌روز) می‌توان به عملکرد مناسب رسید و سپس سربار آموزشی را کاهش داد. برای سناریوهای تحرک نیز نسخه اصلاح‌شده‌ای مطرح می‌شود که از چند نگاشت توان برای نواحی فاصله‌ای مختلف استفاده می‌کند.

7-8) نتایج عددی کلیدی و جمع‌بندی

• **بهبود EPP:** در شبکه‌های پرتراکم، کارایی انرژی (EPP) تا 26 برابر بهتر از برخی الگوریتم‌ها (مانند EARN) گزارش شده است.

• **Goodput:** افزایش خطی توان عملیاتی (Goodput) با افزایش بار ترافیک گزارش می‌شود، در حالی که روش‌های دیگر افت شدیدتر دارند.

• **همگرایی:** رسیدن به پایداری در ده‌ها ساعت (در مقابل هزاران ساعت برای برخی روش‌های MAB قبلی) گزارش شده است.

• **محدودیت‌ها:** نیاز به ACK در فاز آموزش و پیچیدگی دو مرحله‌ای (ML + RL).

8) مقایسه نظام‌مند سه رویکرد و تحلیل نهایی

8-1) جدول مقایسه ساختاری (خلاصه)

بُعد	LP-MAB	ML-Assisted TPC	Intelligent Resource Allocation	برداشت/نکته ارائه‌ای
محل اجرا	متمرکز (NS)	غیرمتمرکز (EN)	ترکیبی (TP متمرکز SF/CR + غیرمتمرکز)	انتخاب محل اجرا باید با محدودیت‌های downlink ، توان پردازشی گره، و نیاز به دید شبکه‌ای هم‌راستا باشد.
مزیت عملیاتی	دید شبکه‌ای (Global View) و عدم تحمیل محاسبات سنگین به گره	واکنش سریع، حذف/کاهش وابستگی به تاریخچه SNR، کاهش نیاز به فرمان از NS	کوچک‌سازی فضای عمل RL و همگرایی سریع‌تر در ازدحام بالا	مزیت‌ها عمدتاً به «جایی که تصمیم گرفته می‌شود» و «هزینه یادگیری/کنترل» برمی‌گردند.

محدودیت کلیدی	وابستگی به بازخورد/ACK و حساسیت به نرخ ارسال برای یادگیری	نیاز به مدل آموزش دیده و ویژگی های محیطی (کالیبراسیون/بازآموزی)	نیاز به ACK در فاز آموزش و اثر روی ظرفیت downlink	در عمل، محدودیت ها معمولاً یا داده/کالیبراسیون هستند یا ظرفیت downlink و duty-cycle.
نوع یادگیری/مناطق تصمیم	MAB/RL: SE + EXP3	Supervised ML + (SNR پیش بینی) TPC قواعد	Supervised (TP) + Contextual Bandit (EXP4)	انتخاب رویکرد یادگیری تابع «پویایی محیط» و «هزینه اکتشاف» است.
پارامترهای کنترل	SF/TP/CF/CR	عمدتاً TP و SF (با SNR پیش بینی شده و LM/Me)	TP + SF/CR	پوشش چندپارامتری بهتر است، اما فضای عمل بزرگ تر می تواند یادگیری را سخت تر کند.
نیاز به Downlink	بالا (برای ارسال تنظیمات و/یا ACK)	حداقل برای تنظیم (تصمیم محلی روی گره)	متوسط (ACK آموزشی)	در شبکه های با محدودیت downlink، روش های محلی یا با نیاز ACK کمتر مزیت دارند.
معیارهای برجسته ارزیابی	(EC) و انرژی PDR	انرژی + برخورد با حفظ PDR بالا	در EPP و Goodput ازدحام بالا	انتخاب معیار گزارش دهی مهم است؛ Goodput/EPP برای ازدحام شبکه تصویر جامع تری می دهد.

8-2 برداشت های تحلیلی

1. اگر مسئله اصلی «نوسان شدید کانال» و «فاصله زمانی زیاد بین ارسال ها» باشد، روش ML-Assisted TPC به دلیل حذف وابستگی به تاریخچه SNR و امکان اجرا روی EN، از منظر پاسخ گویی و عملیاتی جذاب است.

2. اگر هدف اصلی «بهبود عملکرد شبکه در ازدحام بالا» همراه با معیارهای سطح شبکه (Goodput/EPP) باشد، چارچوب دو مرحله ای مقاله 3 به دلیل کوچک سازی فضای عمل

RL و همگرایی سریع EXP4 مزیت قابل توجهی دارد، اما سربار ACK آموزشی باید مدیریت شود.

3. LP-MAB برای اپراتورهایی مناسب است که می‌خواهند کنترل را در NS نگه دارند و از مدل داده اولیه بی‌نیاز باشند؛ با این حال در نرخ ارسال پایین، زمان یادگیری و وابستگی به ACK باید دیده شود.

4. هیچ رویکردی را نمی‌توان «مطلقاً» برتر دانست؛ انتخاب روش به قیود سامانه و سناریوی عملیاتی وابسته است، از جمله محدودیت‌های downlink، امکان اندازه‌گیری یا برآورد متغیرهای محیطی، تراکم و الگوی ترافیکی گره‌ها، میزان تحرک

3-8) تحلیل تطبیقی (انرژی/قابلیت اطمینان/ریسک عملیاتی)

انرژی: ML-Assisted TPC با حذف نیاز به دریافت دستورات از NS، پتانسیل کاهش انرژی مستقیم دارد (بهبود حدود 47 درصد گزارش شده). مقاله 3 با بهینه‌سازی EPP در شبکه‌های شلوغ، از هدررفت انرژی ناشی از برخورد جلوگیری می‌کند (بهبودهای بزرگ EPP گزارش شده).

قابلیت اطمینان LP-MAB: PDR/PRR و مقاله 3 به دلیل یادگیری از تعامل و بازخورد (ACK)، در مقابله با تداخل دینامیک می‌توانند سازگارتر باشند. ML-Assisted TPC بیشتر به شرایط فیزیکی/محیطی کانال حساس است و باید در سناریوهایی که تداخل غالب است، رفتار آن دقیق بررسی شود.

ریسک عملیاتی: LP-MAB ریسک گلوگاه/پیچیدگی در NS و وابستگی به سیاست downlink را دارد. ML-Assisted TPC ریسک هزینه سخت‌افزاری سنسورها و نیاز به کالیبراسیون مدل را تحمیل می‌کند. مقاله 3 ریسک پیچیدگی دو مرحله‌ای و نیاز به ACK در آموزش را دارد.

(10 منابع (سه مقاله)

1. LP-MAB: Improving the Energy Efficiency of LoRaWAN Using a Reinforcement-Learning-Based Adaptive Configuration Algorithm
2. Machine-Learning-Assisted Transmission Power Control for LoRaWAN Considering Environments With High Signal-to-Noise Variation
3. Intelligent Resource Allocation in LoRaWAN Using Machine Learning Techniques